Projeto AM-NS 2026-2

Francisco de A. T. de Carvalho[1]

1 Centro de Informatica-CIn/UFPE
Av. Prof. Luiz Freire, s/n -Cidade Universitaria, CEP 50740-540, Recife-PE, Brasil,
fatc@cin.ufpe.br

Questão 1

- Considere a base de dados "iris" (Arquivos anexados com o projeto, https://archive.ics.uci.edu/dataset/53/iris)
- Use a ferramenta da sua escolha (scikit learn https://scikit-learn.org/stable/, WEKA https://www.cs.waikato.ac.nz/ml/weka/, R, Matlab, etc)
- Execute cada um dos 7 algoritmos de agrupamento indicados para a sua equipe, uma vez para o aglomerativo hierarquico e DBSCAB, e 10 vezes com $k \in \{1, 2, 3, 4, 5\}$ para os algoritmos de tipo k-means, fuzzy k-means e mistura EM.
- No caso dos algoritmos de tipo k-means, para cada k (executado 10 vezes) selecione o melhor resultado segundo a função objetivo. Para cada k, calcule a silhueta (Sil). Faça o plot $Sil \times k$ para $k \in \{1, 2, 3, 4, 5\}$ e escolha o número de grupos: $k* = art \max_k Sil(k)$. Para a partição crisp com k^* dada por cada algoritmo de tipo k-means calcule o índice de Rand corrigido. Comente.
- No caso dos algoritmos de tipo fuzzy k-means para cada k (executado 10 vezes) selecione o melhor resultado segundo a função objetivo. Em seguida obtenha uma partição exclusiva (crisp, hard) a partir da partição não exclusiva (fuzzy). Para cada k, calcule a silhueta (Sil). Faça o plot $Sil \times k$ para $k \in \{1, 2, 3, 4, 5\}$ e escolha o número de grupos: $k* = art \max_k Sil(k)$. Para a partição crisp com k^* dada por cada algoritmo de tipo fuzzy k-means calcule o índice de Rand corrigido. Comente.

Questão 1

- No caso do algoritmo misturas EM, para cada k (executado 10 vezes) selecione o melhor resultado segundo a função objetivo. Em seguida obtenha uma partição exclusiva (crisp, hard) a partir da partição não exclusiva (probabilista). Para cada k, calcule a silhueta (Sil). Faça o plot $Sil \times k$ para $k \in \{1, 2, 3, 4, 5\}$ e escolha o número de grupos: $k* = art \max_k Sil(k)$. Para a partição crisp com k^* dada pelo algoritmo EM, calcule o índice de Rand corrigido. Comente.
- Para a execução do aglomerativo hierarquico, excute o mesmo uma vez e a partir do dendograma, obtenha uma partição em $k \in \{1, 2, 3, 4, 5\}$. Para cada k, calcule a silhueta (Sil). Faça o plot $Sil \times k$ para $k \in \{1, 2, 3, 4, 5\}$ e escolha o número de grupos: $k* = art \max_k Sil(k)$. Para a partição crisp com k^* dada pelo algoritmo aglomerativo hierarquico calcule o índice de Rand corrigido. Comente.
- Para a execução do DBSCAN, para o numero de clusters encontrado calcule a silhueta e o índice de Rand corrigido. Comente.

Questão 2

- Considere a base de dados "iris" (Arquivos anexados com o projeto, https://archive.ics.uci.edu/dataset/53/iris)
- Use a ferramenta da sua escolha (scikit learn https://scikit-learn.org/stable/, WEKA https://www.cs.waikato.ac.nz/ml/weka/, R, Matlab, etc)
- Execute uma PCA na base de dados iris. Mostre as saidas padrões da ferramenta para a PCA e o plot com as duas primeiras componentes principais. Comente.
- Execute um kernel PCA na base de dados iris. Mostre as saidas padrões da ferramenta para o kernel PCA e o plot com as duas primeiras componentes principais. Comente.
- Execute o t-SNE na base de dados iris e mostra as saidas comuns da ferramenta que você escolheu. Mostre também o plot 2D usando o t-SNE. Comente
- Execute o UMAP na base de dados iris e mostra as saidas comuns da ferramenta que você escolheu. Mostre também o plot 2D usando o UMAP. Comente

Algoritmos de agrupamento da questão 1 a serem usados pelas equipes

- todos os algoritmos desse projeto podem ser encontrados no scikit learn, Rm MATLAB e em outros lugares
- Todas as equipes vão executar os algoritmos, k-means, fuzzy k-means, misturas (EM) e DBSCAN.
- Equipe 1: também executa o kernel kmeans, o fuzzy k-medoids (use a distancia de city-block) e o aglomerativo hierarquico single linkage (use a distancia de Euclidiana)
- Equipe 2: também executa o kernel kmeans, o fuzzy k-medoids (use a distancia de Euclidiana) e o aglomerativo hierarquico complete linkage (use a distancia de city-block)
- Equipe 3: também executa o kernel-kmeans, o fuzzy k-medoids (use a distancia de city-block) e o aglomerativo hierarquico Unweighted average linkage clustering, UPGMA (use a distancia de Euclidiana)
- Equipe 4: também executa o kernel-kmeans, o fuzzy k-medoids (use a distancia de Euclidiana) e o aglomerativo hierarquico Centroid linkage clustering (UPGMC)
- Equipe 5: também executa o kernel-kmeans, o fuzzy k-medoids (use a distancia de city-block) e o aglomerativo hierarquico Ward linkage (Minimum Increase of Sum of Squares, MISSQ)

Algoritmos de agrupamento da questão 1 a serem usados pelas equipes

- todos os algoritmos desse projeto podem ser encontrados no scikit learn, Rm MATLAB e em outros lugares
- Todas as equipes vão executar os algoritmos, k-means, fuzzy k-means, misturas (EM) e DBSCAN.
- Equipe 6: também executa o kernel fuzzy kmeans, o k-medoids (use a distancia de Euclidiana) e o aglomerativo hierarquico single linkage (use a distancia de city-block)
- Equipe 7: também executa o kernel fuzzy kmeans, o k-medoids (use a distancia de city-block) e o aglomerativo hierarquico complete linkage (use a distancia de Euclidiana)
- Equipe 8: também executa o kernel fuzzy kmeans, o k-medoids (use a distancia de Euclidiana) e o aglomerativo hierarquico Unweighted average linkage clustering, UPGMA (use a distancia de city-block)
- Equipe 9: também executa o kernel fuzzy kmeans, o k-medoids (use a distancia de city-block) e o aglomerativo hierarquico Centroid linkage clustering (UPGMC)
- Equipe 10: também executa o kernel fuzzy kmeans, o k-medoids (use a distancia de Euclidiana) e o aglomerativo hierarquico Ward linkage (Minimum Increase of Sum of Squares, MISSQ)

Observações Finais

- O formato do relatorio e livre. Capriche no relatorio. Nao seja muito prolixo nem muito sintetico. Descreva sempre as suas decisoes e escolhas.
- Data de apresentação e entrega do projeto:
  - Equipes 1, 2, 3 e 4: quinta-feira 19/11/2026
  - Equipes 5, 6 e 7: terça-feira 24/11/2026
  - Equipes 8, 9 e 10: quinta-feira 26/11/2026
- Um dos membros da equipe: **colocar no google classroom o relatório do projeto, e os slides da apresentação.**.
- **NÃO COLOCAR ARQUIVO ZIPADO**
- Tempo de apresentação: **30 minutos** para cada equipe incluindo discussao (**rigoroso**).
- **A presença e a participação de todos os membros de cada equipe é obrigatória durante a apresentação**;